

TRANSLATING PYSPARK PIPELINES TO DASK

ASSISTANT
CODE

Berline Niyonkuru

Sommaire

- 1 INTRODUCTION
- 2 PIPELINE
- 3 BENCHMARK
- 4 INTERFACE UTILISATEUR
- 5 PERSPECTIVES/CONCLUSION

Introduction




Apache Spark est largement utilisé pour le traitement de données massives, mais il reste lourd et peu intégré à l'écosystème Python.

Dask, plus léger et flexible, offre une alternative mieux adaptée aux workflows modernes de data science.

Pourtant, la migration Spark → Dask est peu documentée et complexe.

Ce projet cherche à répondre à cette problématique en proposant une méthodologie outillée pour faciliter et comparer cette migration

Pipeline



Benchmark

Avant profiling

	Pipeline	PySpark (s)	Dask (s)	Gain ×
0	Script 001	0.06	0.03	2
1	Script 005	0.02	0.02	1
2	Script 031	0.02	0.02	1
3	Script 015	0.02	0.02	1
4	Script 004	0.02	0.03	0.67
5	Script 006	0.02	0.02	1

Benchmark

Après profiling et optimisation

	Pipeline	PySpark original (s)	PySpark optimisé (s)	Dask Ultra-Perf (s)	Gain optimisé (×)	Gain Dask vs original (×)	Dask vs optimisé (×)
0	script_005	0.24	0.11	0.02	2.18	12	5.5
1	script_031	0.03	0.03	0.02	1	1.5	1.5
2	script_021	0.03	0.03	0.02	1	1.5	1.5

Interface utilisateur

Démonstration sur l'application Streamlit

Perspectives/Conclusion

- Amélioration de l'interface utilisateur
- Donner plus de choix à l'utilisateur comme par exemple: chercher une pipeline spécifique



Merci.